



ΠΑΝΕΠΙΣΤΗΜΙΟ ΙΩΑΝΝΙΝΩΝ

ΤΜΗΜΑ ΜΗΧΑΝΙΚΩΝ Η/Υ ΚΑΙ ΠΛΗΡΟΦΟΡΙΚΗΣ

ΜΥΕ041 - ΠΛΕ081: Διαχείριση Σύνθετων Δεδομένων
(ΕΑΡΙΝΟ ΕΞΑΜΗΝΟ 2025-26)

ΕΡΓΑΣΙΑ 2 – Χωρικά Δεδομένα

Προθεσμία: 27 Απριλίου 2026, 23:59

Στόχος της εργασίας είναι η ανάπτυξη τεχνικών δεικτοδότησης (δηλ. ευρετηρίασης) και αναζήτησης χωρικών δεδομένων.

Μέρος 1 (προγραμματιστικό)

Κατεβάστε το αρχείο `Beijing_restaurants.txt` από το `ecourse`. Το αρχείο περιέχει τις συντεταγμένες 51970 σημείων τα οποία είναι θέσεις εστιατορίων στο Πεκίνο. Η πρώτη γραμμή του αρχείου είναι το πλήθος των σημείων και κάθε άλλη γραμμή περιέχει τις συντεταγμένες x και y ενός εστιατορίου χωρισμένες με κενό.

Γράψτε ένα πρόγραμμα το οποίο θα υλοποιεί την τεχνική `sort-tille-recursive` (STR) για να φτιάξει ένα R-tree στη κύρια μνήμη. Το δέντρο σας θα πρέπει να έχει δύο τύπων κόμβους: φύλλα και μη-φύλλα (ενδιάμεσοι). Τα φύλλα αποθηκεύουν εγγραφές τύπου `<record-id, point>` ενώ οι ενδιάμεσοι κόμβοι εγγραφές του τύπου `<node-id, MBR>`. Ένα `point` αντιστοιχεί σε μία πλειάδα $\langle x, y \rangle$, ενώ ένα `MBR` σε μία πλειάδα $\langle x\text{-low}, y\text{-low}, x\text{-high}, y\text{-high} \rangle$. Θεωρήστε ότι το `record-id` αντιστοιχεί στη γραμμή στην οποία βρίσκεται το αντίστοιχο σημείο στο αρχείο. Δηλαδή το εστιατόριο με συντεταγμένες 39.856138,116.42394 έχει `record-id` 1, το εστιατόριο με συντεταγμένες 39.813336,116.486149 έχει `record-id` 2, κλπ.

Χωρητικότητα κόμβων

Υποθέστε ότι κάθε κόμβος του δέντρου έχει χωρητικότητα 1024 bytes και ότι χρησιμοποιούμε 8 bytes για κάθε συντεταγμένη και 4 bytes για κάθε `node-id` ή `record-id`. Αξιοποιώντας αυτή την πληροφορία γνωρίζετε ότι:

- Μία εγγραφή σε ένα φύλλο του δέντρου καταλαμβάνει συνολικά 20 bytes. Επομένως η μέγιστη χωρητικότητα ενός φύλλου είναι: $M_L = \lfloor 1024/20 \rfloor = 51$.
- Μία εγγραφή σε ένα ενδιάμεσο κόμβο του δέντρου καταλαμβάνει συνολικά 36 bytes. Επομένως η μέγιστη χωρητικότητα ενός ενδιάμεσου κόμβου είναι: $M_{Int} = \lfloor 1024/36 \rfloor = 28$.

Κατά την κατασκευή του δέντρου θα πρέπει να λάβετε υπόψιν πως ένας κόμβος σε οποιοδήποτε επίπεδο (με εξαίρεση τη ρίζα), δεν μπορεί να έχει εγγραφές λιγότερες από το 40% της μέγιστης χωρητικότητάς του. Συνεπώς ο ελάχιστος αποδεκτός αριθμός εγγραφών σε ένα φύλλο είναι: $m_L =$

$\lfloor 0.4 \times M_L \rfloor = 20$. Αντίστοιχα σε ένα ενδιάμεσο κόμβο, ο ελάχιστος αποδεκτός αριθμός εγγραφών είναι: $m_{int} = \lfloor 0.4 \times M_{int} \rfloor = 11$.

Αυτό σημαίνει πως αν ο τελευταίος κόμβος στο επίπεδο των φύλλων έχει λιγότερες από 20 εγγραφές, τότε πρέπει να προσαρμόσετε τον αριθμό των εγγραφών ώστε να έχει ακριβώς 20 εγγραφές και ο προηγούμενος να έχει λιγότερες από 51. Με την ίδια λογική, σε ένα ενδιάμεσο επίπεδο του δέντρου, αν ο τελευταίος κόμβος έχει λιγότερες από 11 εγγραφές, πρέπει να προσαρμόσετε τις εγγραφές του ώστε να έχει ακριβώς 11, με τον προηγούμενό του να έχει λιγότερες από 28. Επισημαίνεται ξανά ότι η ρίζα του δέντρου αποτελεί εξαίρεση, καθώς μπορεί να έχει από 2 μέχρι 28 εγγραφές.

Υλοποίηση STR R-tree

Στην υλοποίησή σας θα πρέπει να διαβάσετε τα δεδομένα από το αρχείο, να κάνετε την ταξινόμηση (χρησιμοποιήστε έτοιμες συναρτήσεις ταξινόμησης στη μνήμη και όχι external sorting) και να φτιάξετε το δέντρο στη μνήμη. Θα χρησιμοποιήσετε μια δομή array ή vector για να αποθηκεύσετε τους κόμβους. Καθώς φτιάχνετε το δέντρο, θα προσθέτετε τους κόμβους στο array ή vector και το node-id ενός κόμβου θα είναι η θέση του στο array ή vector. Με αυτό τον τρόπο προσομοιώνουμε μια ακολουθία από blocks στο δίσκο που αποθηκεύουν το δέντρο.

Για τις λεπτομέρειες του STR bulk loading μπορείτε να ανατρέξετε στις σημειώσεις του μαθήματος ή στο παρακάτω άρθρο:

<https://pdfs.semanticscholar.org/e680/839472e7f5cab0f12fcc7c4aba6834a2e096.pdf>

Το πρόγραμμά σας **θα πρέπει να τυπώνει στατιστικά για το δέντρο**: ύψος, αριθμός κόμβων σε κάθε επίπεδο, και μέσο εμβαδό των MBRs σε κάθε επίπεδο (στο επίπεδο των φύλλων το μέσο εμβαδό είναι 0, γιατί τα φύλλα αποθηκεύουν σημεία). Η μορφή των μηνυμάτων είναι η εξής:

```
1020 nodes at level 0 with average MBR area 0.0
37 nodes at level 1 with average MBR area 0.014773812397702606
2 nodes at level 2 with average MBR area 0.1640782578990009
1 nodes at level 3 with average MBR area 0.3246387377100014
```

Επίσης θα πρέπει να γράφει σε ένα text αρχείο εξόδου **rtree.csv** (CSV = comma separated values) την αναπαράσταση του δέντρου. Κάθε γραμμή του αρχείου θα περιέχει τα δεδομένα ενός κόμβου, ακολουθώντας bottom-up αναπαράσταση και με την τελευταία γραμμή να αφορά τη ρίζα του δέντρου. Η αποθήκευση των κόμβων θα ακολουθεί την εξής μορφή:

node-id, n, f, (ptr1, geo1), (ptr2, geo2), ..., (ptrn, geon)

όπου node-id είναι το id του κόμβου, n ο αριθμός των εγγραφών στον κόμβο, f είναι ένα binary flag με τιμή 0 ή 1 ανάλογα με το αν ο κόμβος είναι φύλλο ή όχι, και ακολουθούν οι n εγγραφές μέσα στον κόμβο. Σε κάθε εγγραφή, το ptr είναι είτε ένα node-id (αν η εγγραφή δείχνει σε ενδιάμεσο κόμβο) είτε ένα record-id αν η εγγραφή δείχνει σε αντικείμενο. Το geo είναι είτε μία ακολουθία 2 αριθμών αν πρόκειται για σημείο (δηλ., οι συντεταγμένες του), ή 4 αριθμών αν πρόκειται για MBR.

Ακολουθούν στιγμιότυπα για την αναπαράσταση των φύλλων και των ενδιάμεσων κόμβων:

```
0 , 51 , 0 , (42474,(39.74118, 116.070466)) , (42475,(39.74118, 116.070466)) ,  
...  
1 , 51 , 0 , (20524,(39.729734, 116.11993)) , (28356,(39.728809, 116.119954)) ,  
...
```

```
1020 , 28 , 1 , (0,[39.682541, 116.070466, 39.74118, 116.119867]) ,  
(1,[39.702303, 116.11993, 39.742855, 116.124083]) , ...  
1021 , 28 , 1 , (28,[39.709618, 116.421455, 39.745567, 116.429803]) ,  
(29,[39.69295, 116.429821, 39.74489, 116.462999]) , ...
```

ΠΡΟΣΟΧΗ: Το ζητούμενο είναι η πανομοιότυπη αναπαράσταση του δέντρου στο αρχείο `rtree.csv` με αυτή που παρουσιάζεται στα προηγούμενα στιγμιότυπα. Δώστε ιδιαίτερη προσοχή στις παρενθέσεις και στα κενά πριν και μετά από κάθε κόμμα. Εργασίες που δεν θα ακολουθούν αυτό το πρότυπο αποθήκευσης, θα έχουν ποινή στην τελική βαθμολογία.

Εκτέλεση προγράμματος

Το πρόγραμμά σας θα πρέπει να τρέχει στη γραμμή διαταγών και να παίρνει σαν ορίσματα το αρχείο με τα δεδομένα και το όνομα του αρχείου εξόδου.

Μέρος 2 (προγραμματιστικό)

Σε αυτό το μέρος καλείστε να υλοποιήσετε κάποιες μεθόδους για την αποτίμηση ερωτήσεων χρησιμοποιώντας το R-tree που υλοποιήσατε στο Μέρος 1. Για όλες τις μεθόδους θα πρέπει να διαβάσετε εξ ολοκλήρου το αρχείο με το δέντρο (**`rtree.csv`**) και να φτιάχνετε μία αναπαράστασή του όπως στο προηγούμενο μέρος (δηλ., σε μια δομή array ή vector). Ακολουθούν οι περιγραφές των μεθόδων.

Ερωτήσεις Εύρους με τη χρήση Παραθύρου (Window Range Queries)

Δοθέντος ενός παραθύρου W , το ζητούμενο είναι να βρεθούν όλα τα σημεία στο R-tree, τα οποία επικαλύπτονται από το W (συμπεριλαμβανομένων και των σημείων πάνω στο περίγραμμά του). Το παράθυρο W αναπαρίσταται με τη μορφή ενός MBR.

Υλοποιήστε μία συνάρτηση η οποία παίρνει σαν όρισμα το node-id της ρίζας του R-tree και το παράθυρο W και επιστρέφει μία λίστα με τα σημεία που είναι αποτελέσματα. Η συνάρτηση μπορεί να διασχίζει το δέντρο αναδρομικά ή με τη χρήση βοηθητικής δομής, η οποία κρατά τους κόμβους που πρέπει να εξεταστούν σε μεταγενέστερα βήματα.

Θα πρέπει να υλοποιήσετε επιπλέον δύο βοηθητικές συναρτήσεις. Η πρώτη θα ελέγχει αν ένα MBR σε ένα ενδιάμεσο κόμβο επικαλύπτεται από το παράθυρο W . Η δεύτερη θα ελέγχει αν μία εγγραφή σε ένα φύλλο επικαλύπτεται από το παράθυρο W . Για περισσότερες λεπτομέρειες που αφορούν την

υλοποίηση μπορείτε να ανατρέξετε στις διαφάνειες (47-53) της συγκεκριμένης ενότητας του μαθήματος.

Για να αξιολογήσετε την ορθότητα της υλοποίησής σας, χρησιμοποιήστε το αρχείο **windowRangeQueries.txt**. Κάθε γραμμή του αρχείου αντιστοιχεί σε ένα παράθυρο W (δηλ., σε μία ερώτηση) και έχει τη μορφή [x-low y-low x-high y-high]. Το αρχείο θα πρέπει να δίνεται ως όρισμα στο πρόγραμμά σας από τη γραμμή διαταγών. Για καθεμία ερώτηση θα πρέπει να εμφανίζετε στην οθόνη τη γραμμή της (αρχίζοντας από τη γραμμή 0), τον αριθμό των αποτελεσμάτων σε παρένθεση, και τα record-ids των αποτελεσμάτων χωρισμένα με κόμμα. Ακολουθεί στιγμιότυπο με τη ζητούμενη έξοδο του προγράμματος για τις τρεις πρώτες ερωτήσεις:

```
0 (15): 20092,21791,17364,41338,41561,32932,7555,51960,43959,50073,...
1 (48): 33905,37247,36551,12348,3012,35616,8129,42824,9816,27944,...
2 (89): 46264,8128,22360,48035,49349,27575,35558,33637,22317,47697,...
```

Ερωτήσεις Εύρους με βάση την Απόσταση (Distance Range Queries)

Δοθέντος ενός σημείου αναφοράς q και μίας τιμής ϵ , το ζητούμενο είναι η ανάκτηση όλων των σημείων στο R-tree, τα οποία δεν βρίσκονται σε απόσταση μεγαλύτερη από ϵ (δηλ., $\forall p \in \text{R-tree}: \text{dist}(q,p) \leq \epsilon$). Επομένως, καλείστε να ανακτήσετε όλα τα σημεία που περιλαμβάνονται εντός ενός κύκλου $C(q, \epsilon)$, με το q και το ϵ να είναι το κέντρο και η ακτίνα του, αντίστοιχα.

Υλοποιήστε μία συνάρτηση, η οποία παίρνει σαν όρισμα το node-id της ρίζας του R-tree, το σημείο q μαζί με την ακτίνα ϵ και επιστρέφει μία λίστα με τα σημεία που είναι αποτελέσματα. Η συνάρτηση μπορεί να διασχίζει το δέντρο αναδρομικά ή με τη χρήση βοηθητικής δομής, η οποία κρατά τους κόμβους που πρέπει να εξεταστούν σε μεταγενέστερα βήματα.

Θα πρέπει να υλοποιήσετε επιπλέον δύο βοηθητικές συναρτήσεις. Η πρώτη θα υπολογίζει την ελάχιστη απόσταση ενός MBR σε ένα ενδιάμεσο κόμβο από το σημείο q . Η δεύτερη θα υπολογίζει την απόσταση μίας εγγραφής σε ένα φύλλο από το σημείο q . Για περισσότερες λεπτομέρειες που αφορούν την υλοποίηση μπορείτε να ανατρέξετε στις διαφάνειες (54 και 55) της συγκεκριμένης ενότητας του μαθήματος.

ΣΗΜΕΙΩΣΗ: Ως μετρική για τον υπολογισμό των αποστάσεων χρησιμοποιήστε την Ευκλείδεια απόσταση. Όπως έχει αναφερθεί και στο μάθημα, προκύπτει από τον υπολογισμό της ρίζας του αθροίσματος των τετραγωνισμένων αποστάσεων σε κάθε διάσταση.

Για να αξιολογήσετε την ορθότητα της υλοποίησής σας, χρησιμοποιήστε το αρχείο **distanceRangeQueries.txt**. Κάθε γραμμή του αρχείου αντιστοιχεί στις συντεταγμένες της ερώτησης μαζί με την ακτίνα ϵ και έχει τη μορφή [x y ϵ]. Το αρχείο θα πρέπει να δίνεται ως όρισμα στο πρόγραμμά σας από τη γραμμή διαταγών. Για καθεμία ερώτηση θα πρέπει να εμφανίζετε στην οθόνη τη γραμμή της (αρχίζοντας από τη γραμμή 0), τον αριθμό των αποτελεσμάτων σε παρένθεση, και τα record-ids των αποτελεσμάτων χωρισμένα με κόμμα. Ακολουθεί στιγμιότυπο με τη ζητούμενη έξοδο του προγράμματος για τις τρεις πρώτες ερωτήσεις:

0	(62):	36666,10840,17494,48915,46118,47057,41093,28134,45731,4282,...
1	(29):	8496,51939,5631,24420,50152,10708,3467,41211,5908,8481,...
2	(105):	8428,10008,43540,2135,40883,2445,21026,51606,1475,28605,...

Ερωτήσεις k Πλησιέστερων Γειτόνων (kNN Queries)

Δοθέντος ενός σημείου αναφοράς q και μίας ακέραιας τιμής k , το ζητούμενο είναι η ανάκτηση των k πλησιέστερων σημείων στο R-tree. Υλοποιήστε μία συνάρτηση, η οποία παίρνει σαν όρισμα το node-id της ρίζας του R-tree, το σημείο q μαζί με την τιμή k και εφαρμόζει τον αλγόριθμο best-first search επιστρέφοντας μία λίστα με τα σημεία που είναι αποτελέσματα.

Η έκδοση του αλγορίθμου θα πρέπει να είναι εκείνη που κάνει incremental NN search και χρησιμοποιεί μία ουρά προτεραιότητας για να οργανώσει τις εγγραφές των κόμβων του R-tree σε αύξουσα σειρά, χρησιμοποιώντας ως κριτήριο την απόσταση που έχουν από το σημείο q . Πιο αναλυτικά, η ουρά προτεραιότητας θα πρέπει να αποθηκεύει τόσο τα MBRs ενός εξεταζόμενου ενδιαμέσου κόμβου, όσο και τα σημεία που εντοπίζονται στα φύλλα του δέντρου. Όταν ένα σημείο βγαίνει από την ουρά είναι και ο επόμενος πλησιέστερος γείτονας του q .

Θα πρέπει να υλοποιήσετε επιπλέον δύο βοηθητικές συναρτήσεις. Η πρώτη θα υπολογίζει την ελάχιστη απόσταση ενός MBR σε ένα ενδιαμέσο κόμβο από το σημείο q . Η δεύτερη θα υπολογίζει την απόσταση μίας εγγραφής σε ένα φύλλο από το σημείο q . Για περισσότερες λεπτομέρειες που αφορούν την υλοποίηση μπορείτε να ανατρέξετε στις διαφάνειες (99-107) της συγκεκριμένης ενότητας του μαθήματος.

ΣΗΜΕΙΩΣΗ: Ως μετρική για τον υπολογισμό των αποστάσεων χρησιμοποιείτε την Ευκλείδεια απόσταση. Όπως έχει αναφερθεί και στο μάθημα, προκύπτει από τον υπολογισμό της ρίζας του αθροίσματος των τετραγωνισμένων αποστάσεων σε κάθε διάσταση.

Για να αξιολογήσετε την ορθότητα της υλοποίησής σας, χρησιμοποιήστε το αρχείο **NNQueries.txt**. Κάθε γραμμή του αρχείου αντιστοιχεί στις συντεταγμένες της ερώτησης και έχει τη μορφή $[x\ y]$. Το αρχείο θα πρέπει να δίνεται ως όρισμα στο πρόγραμμά σας από τη γραμμή διαταγών, συνοδευόμενο από μία επιλεγμένη τιμή k . Για καθεμία ερώτηση θα πρέπει να εμφανίζετε στην οθόνη τη γραμμή της (αρχίζοντας από τη γραμμή 0) και τα record-ids των αποτελεσμάτων χωρισμένα με κόμμα. Ακολουθεί στιγμιότυπο με τη ζητούμενη έξοδο του προγράμματος για τις τρεις πρώτες ερωτήσεις αναζητώντας τους 10 πλησιέστερους γείτονες:

0:	46099,8127,21812,41533,14833,1217,23761,27872,7544,43344
1:	7714,41566,10418,22944,38417,2038,27709,44845,16263,46309
2:	32186,50968,49548,28030,27262,32201,15276,33770,33771,33768

ΠΡΟΣΟΧΗ: Το ζητούμενο είναι η πανομοιότυπη εμφάνιση των μηνυμάτων με αυτή που παρουσιάζεται στα προηγούμενα στιγμιότυπα. Δώστε ιδιαίτερη προσοχή στα κενά. Εργασίες που δεν θα ακολουθούν αυτό το πρότυπο εκτύπωσης, θα έχουν ποινή στην τελική βαθμολογία.

Απορίες – Διευκρινίσεις

Για απορίες και διευκρινίσεις μπορείτε να αποστείλετε email στο βοηθό του μαθήματος που αξιολόγησε την 1^η εργασία. Μπορείτε να ανατρέξετε στο pdf που είναι αναρτημένο στη σελίδα του μαθήματος στο ecourse για να βρείτε το βοηθό που μπορείτε να απευθυνθείτε. Προσπαθήστε να είναι σαφές το θέμα και το περιεχόμενο των emails σας.

Παραδοτέα

Κάντε turnin στο assignment2@mye041 τα προγράμματά σας και ένα PDF αρχείο το οποίο τεκμηριώνει τα προγράμματα και περιέχει διευκρινίσεις ως προς τη λειτουργία τους.

Οδηγίες για τις υποβολές:

- 1) Μπορείτε να χρησιμοποιήσετε δομές όπως priority queue ή heap από τις βιβλιοθήκες της γλώσσας προγραμματισμού (π.χ. το module heapq της Python) εάν αυτό απαιτείται. Η εργασία θα πρέπει να τρέχει στους υπολογιστές του εργαστηρίου, **χωρίς την εγκατάσταση επιπρόσθετων βιβλιοθηκών.**
- 2) Αν χρησιμοποιήσετε Java, το πρόγραμμά σας θα πρέπει να γίνεται compile και να τρέχει και εκτός Eclipse στους υπολογιστές του εργαστηρίου. **Μην χρησιμοποιείτε packages.**
- 3) Αν χρησιμοποιήσετε Python, μην χρησιμοποιήσετε τη βιβλιοθήκη pandas και μην υποβάλετε κώδικα για interactive programming (π.χ. ipython)
- 4) Υποβάλετε τις εργασίες σας σε ένα **zip** αρχείο (**όχι rar**) το οποίο πρέπει να περιλαμβάνει όλους τους κώδικες καθώς και ένα PDF αρχείο τεκμηρίωσης το οποίο να περιγράφει τη μεθοδολογία σας. **Μην υποβάλετε αρχεία δεδομένων.**
- 5) Μην ξεχνάτε να βάζετε το όνομά σας (σε greeklish) και το ΑΜ σε κάθε αρχείο που υποβάλετε.
- 6) Ο έλεγχος των προγραμμάτων σας μπορεί να γίνει σε άλλα αρχεία εισόδου από αυτά που σας δίνονται, άρα θα πρέπει ο κώδικάς σας να μην εξαρτάται από τα συγκεκριμένα αρχεία εισόδου που σας δίνονται.